

Relatório de Experimentos - Análise Comparativa

Este relatório apresenta os resultados consolidados dos experimentos de machine learning realizados, comparando o baseline inicial com os modelos ajustados via GridSearch, além de detalhar as diferenças entre os datasets utilizados.

1. Comparação de Resultados (Ajustes e Notebooks)

A análise foi dividida em dois momentos principais, refletidos nos notebooks `results.ipynb` (histórico) e `results_2.ipynb` (atualizado):

Ajustes Realizados

- **Filtragem Temporal:** O notebook `results_2.ipynb` foca em resultados obtidos a partir de 19/04, incorporando refinamentos nas técnicas de pré-processamento e hiperparâmetros.
- **Normalização de Métricas:** Identificamos uma inconsistência no log de resultados legados (especialmente para o **Random Forest**), onde os valores eram armazenados em um formato de ponto flutuante não convencional (ex: 9.305.105...). Isso causava a ausência de dados no heatmap (“ficava branco”). O script de sumarização foi corrigido para tratar esses casos, normalizando as métricas para a escala correta (0.0 a 1.0).
- **Feature Engineering:** A transição para os datasets `submodalidade_agrupada` e `engineered` permitiu que modelos como XGBoost atingissem maior estabilidade e performance.


2. Comparativo de Datasets

Foram testados três cenários para avaliar o impacto da granularidade das variáveis de submodalidade:

Dataset	Descrição	Objetivo
sem_submodalidade	Dataset base sem detalhamento de submodalidade.	Estabelecer um baseline simples.
submodalidade_agrupada	Agrupamento de categorias raras ou similares.	Reduzir a esparsidade e ruído dos dados.
submodalidade_engineered	Aplicação de transformações (Target Encoding/Frequency).	Capturar padrões complexos sem aumentar excessivamente a dimensionalidade.

3. Resultados Consolidados (Tuned vs Baseline)

A tabela abaixo resume a performance (ROC AUC) no cenário base (sem_submodalidade), comparando o estado inicial com o modelo otimizado.



Heatmap de Resultados

Resumo de Performance

Modelo	SMOTE	Baseline (Teste)	Tuning (Teste)	Melhoria
Random Forest	Não	0.9305	0.9322	+0.18%
XGBoost	Não	0.9303	0.9304	+0.01%
SVM	Sim	0.8640	0.8640	-
Logistic Regression	Sim	0.8657	0.8657	-
DecisionTree	Não	0.7941	0.9107	+14.68%

*Nota: O XGBoost obteve seu melhor resultado global (**0.9444**) utilizando o dataset submodalidade_agrupada sem SMOTE.*

4. Conclusão

- **Modelos de Árvore:** XGBoost e Random Forest continuam sendo os mais robustos para este problema.
- **SMOTE:** Teve impacto positivo significativo apenas em modelos lineares (Logistic Regression), mas não trouxe ganhos reais para XGBoost/RF.
- **Dataset:** O tratamento das submodalidades (agrupada) é essencial para extrair a performance máxima dos modelos.